

OilSense 系统改进报告

基准版本: OilSense-TA-v1.1 (2026 年 3 月提交版)

改进周期: 2026 年 5 月

团队: Heimdallrs

摘要

本轮改进始于一个具体疑问: 为什么系统在 2026 年霍尔木兹封锁这一真实极端事件中表现不佳? 围绕这个问题的层层追查, 意外揭开了一系列从未被发现的实现缺陷、数据管道缺陷, 乃至文档中的事实性错误。

更重要的是, 追查过程纠正了若干对系统表现的误判——一些看似“模型失败”的现象, 实质是展示层误导、数据标注错误或统计模型的物理边界。本报告不仅记录“改了什么”, 更记录“为什么最初的判断是错的”, 以及“系统真实的能力边界在哪里”。

改进成果可概括为三句话:

- 封锁期第二层从“形同虚设”到“全程接管”: 有效激活天数从 10/50 天提升到 50/50 天, 封锁高峰期方向准确率从约 54% 提升到 71%。
- 澄清了一个被冤枉的“14 天延迟”: 经事实核查, 封锁的真实起始日比文档标注晚了两周, 系统实际在封锁生效首个交易日即触发, 所谓延迟根本不存在。
- 诚实厘清了 LLM 情感因子的真实贡献: 原文档宣称的“情感因子 +1% 提升”在当前数据下无法复现, 根因是历史情感数据管道缺陷, 本轮已补全数据并对结论作出修正。

第一部分 对真实极端事件表现的深度审查

霍尔木兹封锁是 OilSense 上线以来遭遇的第一个真正意义上的样本外极端事件 (训练数据截止 2026-01-01, 模型从未见过这次封锁)。它成为检验“双层架构”设计是否成立的试金石。审查从两个肉眼可见的“异常现象”开始。

1.1 异常现象 A: 回测曲线“过拟合”

初始判断: 回测主图中, 模型预测线在 2020 - 2025 年段与实际走势贴合度异常高, 疑似过拟合。

追查结论——这是展示层误导, 不是过拟合。

回测主图遍历 feature_matrix 全部 1576 行, 但其中 1486 行 (94%) 属于训练集内数据 (训练截止 2026-01-01)。模型在自己见过的数据上拟合得好是必然的, 把 in-sample 预测当作“回测”展示, 自然产生过拟合的错觉。真正的样本外预测只有 2026-01 之后的约 90 行。

数据段	行数	性质
2020-03 ~ 2025-12	1486	训练集内 (in-sample)
2026-01 ~ 至今	~90	真实样本外 (OOS)

修复：回测图新增训练截止竖线（2026-01-01），明确区分 in-sample 与 OOS 区段；并将展示从 XGBoost 原始输出改为经门控的综合输出（详见第三部分）。

1.2 异常现象 B：封锁期模型“毫无反应”

这是本轮审查最曲折的一条线索，经历了四层认知迭代，每一层都推翻了上一层的结论。

第一层认知——以为是 z-score 自归一化衰减。

触发条件依赖 `hormuz_tanker_zscore` ($|z|>2$)。z-score 基于 90 日滚动均值，封锁持续后均值自适应下移，z-score 从 -3.5 在两周内衰减到 -1.0，跌破阈值。看起来是“突刺检测器”用错了场景。

第二层认知——发现 `feature_matrix` 里本就有 `hormuz_blocked` 列，但门控函数没用它。

`hormuz_blocked` 是 IMF PortWatch 的直接封锁标志（通过量低于均值 50% 置 1），不受 z-score 衰减影响。但 `get_integrated_output()` 的触发条件压根没引用这一列——黑天鹅检测模块和 `infer_extreme_start` 都用了，唯独负责生成回测预测的函数漏了。

第三层认知——修复门控后，发现第二层内部还有一道独立判断也漏了 `hormuz_blocked`。

`get_integrated_output()` 判定为极端期 → 调用 `get_extreme_prediction()`，但后者内部又有一套独立的 `is_extreme` 判断，同样不含 `hormuz_blocked`。结果：外层认为第二层在跑，内层却因 $z\text{-score} < 2$ 直接返回 XGBoost 原始输出（均值回归看空）。情景匹配从未真正执行。这解释了为什么 3 月 16 日后预测一路看空（-3% ~ -23%），而实际油价在 \$90+ 持续上涨。

第四层认知（决定性）——封锁的起始日期本身就标错了。

在追查“14 天延迟”时，对真实事件时间线做了事实核查（维基百科 2026 Strait of Hormuz crisis），结果颠覆了此前所有分析：

事件	文档标注（错误）	真实日期
危机触发	2026-02-16（虚构）	2026-02-28（美以空袭伊朗、刺杀哈梅内伊）
海峡正式关闭	2026-02-16	2026-03-02（IRGC 官方宣布关闭）
临时停火	—	2026-04-08
再次关闭	—	2026-04-18

`extreme_scenario.py` 里手工标注的 `"start": "2026-02-16"` 是一个不存在的日期——那天什么都没发生。真实的封锁正式生效日是 3 月 2 日（周一），而 PortWatch 的 `hormuz_blocked` 恰恰也在 3 月 2 日首次置 1。

这意味着所谓“系统延迟 14 天才检测到封锁”是一个伪命题——系统实际在封锁生效的第一个交易日就触发了。此前几轮基于错误日期的“漏检”分析全部作废。

修复：

- `extreme_scenario.py`: `start 2026-02-16 → 2026-02-28, typical_30d 0.45 → 0.59`（从封锁生效日 3-02 的 \$71.13 到 30 日后 4-02 的 \$113.23，实测 +59%）。

- `app.py` 三处（危机事件竖线、危机窗口下拉、因果逻辑文案）：日期统一改为 2026-03-02，文案补全为“美以空袭(02-28) → IRGC 关闭(03-02)”。
- `get_integrated_output()` 与 `get_extreme_prediction()`：双双加入 `hormuz_blocked > 0` 触发，两处逻辑对齐。

第二部分 模型性能的诚实再评估

2.1 “58% 方向准确率”到底是不是样本外

审查中专门厘清了原文档“Enhanced 方向准确率约 58%”这一数字的真实含义。`train_model.py` 的实际切分是四段：

数据段	约行数	时间范围（约）	用途
X_tr（拟合）	1009	2020-03 ~ 2024-03	XGBoost 学习权重
X_val（早停）	179	2024-03 ~ 2024-10	early stopping 判停
X_test（评估）	298	2024-10 ~ 2025-12	方向准确率计算处
截止后段	90	2026-01 ~ 至今	从未评估

结论：该数字是真实 OOS（X_test 在训练时未参与权重学习），但有两点须诚实说明——(1) X_val 参与了早停判停，严格意义上只有 X_test 是完全干净的 OOS；(2) 真正意义上“未来”的 90 行（含封锁期）从未进入这个 58% 的统计口径。

2.2 LLM 情感因子的真相（本轮最重要的发现之一）

原文档宣称：Enhanced（含 LLM 情感因子）方向准确率 58%，较 Baseline 提升 +1%，且 `sentiment_score`、`sentiment_accel` 进入特征重要性 Top10。

审查发现，这个结论在当前数据下完全无法复现。

直接核查 `feature_matrix` 发现：训练集中 99.8% 的 `sentiment_score` 值为 0。逐年统计，2020 - 2025 年的 `sentiment_score` 非零天数为 0。换言之，情感因子在训练时是一个常数列，XGBoost 从未用它做任何分裂，特征重要性实测为 0.0——与文档宣称的“进入 Top10”直接矛盾。

根因：`sentiment_analysis.py` 默认 `keep_days=90`，每次运行都会把 90 天前的情感分析结果从文件中裁掉再保存。即使历史上确实跑过情感分析，后续任意一次默认运行都会把历史结果覆盖。当前 `daily_sentiment.csv` 仅剩 2026-03-24 之后的 43 天。

补救尝试与结果（完整记录，含失败）：

- 重建历史新闻库：用 MediaCloud 重新抓取 2022 - 2026 石油新闻。首次按月粒度抓取得 2311 条，但日期分布极差（2022 年文章几乎全堆在每月 1 日，独立日期仅 360 天）。改为按周粒度重抓后得 3708 条，独立日期 587 天，分布显著改善。
- 补跑 DeepSeek 情感分析（`keep_days=0` 保留全量）：`daily_sentiment.csv` 从 43 天扩展到 647 天（2022-01 ~ 2026-05）。
- 重训模型：结果 Enhanced 方向准确率 51.68%，仍低于 Baseline 的 57.05%，情感特征重要性仍接近 0。

- 诊断：情感数据虽补到 647 个日历日，但落到交易日后覆盖率仅 33 - 37%（大量文章日期在周末，无法对齐交易日）。在 60% 以上行仍为 0 的稀疏特征上，XGBoost 无法学到稳定规律。
- “表面保留实际剔除”实验：尝试在训练时排除 4 个稀疏情感列（定义保留、训练剔除），结果 Enhanced 反而退化到 51.34%，RMSE/MAE 同步变差——证明问题不在情感列本身，而在 Enhanced 的 40 维特征集在当前 OOS 测试段整体信噪比不足。已回滚此实验。

最终定位（诚实结论）：

- LLM 情感因子作为训练信号，在当前数据密度下贡献有限；它的价值体现在实时预测端（2026 年这段有真实情感数据时参与当日预测）。
- 系统真正经得起检验的差异化特征是 GDELT 地缘政治 + IMF PortWatch 航运（gdelt_goldstein 稳居特征重要性第一，hormuz_tanker_zscore 真实有效）。
- 模型分工已明确：Baseline 负责方向预测（57%），Enhanced 负责风险区间（覆盖率 93.6%），二者各司其职，这才是系统的实际运行方式。

2.3 区间覆盖率的真实结构

原文档报告整体覆盖率 76%。本轮按市场状态分层重新评估：

数据段	覆盖率	区间平均宽度	\	target\	均值
验证集 OOS（正常市场）	93.6%	30.7%	4.1%		
封锁期（hb=1）	96.1%	49.8%	10.2%		
预封锁期（Jan - Feb 2026）	75.6%	29.0%	10.3%		

关键洞察：封锁期 96.1% 的覆盖率说明第二层激活后区间扩宽是有效的。真正的短板在预封锁期——而且 miss 的样本全部是“实际值突破上界”（单方向系统性低估），无一突破下界。原因见第六部分（信息不对称的物理上限）。

第三部分 Bug 修复清单

#	Bug	严重度	根因	后果	修复
1	get_integrated_output() 缺 hormuz_blocked 触发	严重	z-score 衰减后无补充触发条件	封锁 50 天仅 10 天激活第二层	加 hormuz_blocked>0
2	get_extreme_prediction() 内层触发与外层不一致	严重	内部独立 is_extreme 漏 hormuz_blocked	外层触发但情景匹配从未执行，返回看空原值	内层同步加入

#	Bug	严重度	根因	后果	修复
3	封锁事件起始日错误	严重	手工标注 2026-02-16（虚构日期）	typical_30d 偏低、特征对比基准偏移两周	改 02-28/03-02, typical_30d 0.45→0.59
4	封锁期判断标准漂移	严重	hormuz_blocked 用 90 日滚动均值×50%，封锁数据自我污染	封锁超 90 天后阈值趋近封锁流量本身，可能误判为“正常”	冻结基准法（见下）
5	_infer_trigger_type() 优先级错误	中等	地缘判断优先于宏观	关税冲击期(VIX52/油价-16%)被误判为地缘政治，匹配涨价事件，方向反	宏观冲击优先
6	Quantile Crossing (P50 出界)	中等	三分位数独立训练无单调约束	3.2% 行 P50 超出 P10 - P90，绿线跑出阴影	sorted() 强制单调
7	train_model.py / fetch_portwatch.py 编码 Bug	轻微	打印 ✓ 符号	Windows GBK 终端 UnicodeEncodeError，日志中断	替换为 OK

Bug 4 冻结基准法详解：封锁信号一旦首次触发，立即冻结此前 90 日的预封锁基准均值，此后始终以该冻结值的 50% 为阈值判断，不再让滚动窗口纳入封锁期低流量数据；当连续 3 日通过量回升至冻结基准的 60% 以上时自动重置。这从根本上解决了“持久封锁后期阈值失效”的隐患。

第四部分 第二层模型重构

4.1 全样本触发统计

对 1578 行逐日统计第二层触发情况（改进后）：

- 全量触发 226 天（14.3%），较中间版本（曾达 347 天 / 22%）大幅收敛。
- 触发原因构成：VIX>30（宏观恐慌，新冠/俄乌）132 天、hormuz_blocked（封锁）52 天、|hormuz_z|>2（航运异常）61 天，其余为地缘组合条件。
- 2026 封锁期（92 天）：第二层激活 50 余天，3 - 5 月全程接管。

4.2 触发分类器重写（`\_infer\_trigger\_type`）

原版以“航运异常/地缘”为最高优先级，导致 2025-04 关税冲击（典型宏观需求冲击：VIX=52、油价单周 -16%）被误判为地缘政治，进而匹配到俄乌战争、霍尔木兹封锁等供应中断涨价事件，输出看涨——与实际下跌完全相反。

重写后优先级：① 宏观冲击优先（VIX>35 且 5 日跌幅>5%）→ ② 实际封锁（hormuz_blocked）→ ③ 航运显著异常（z 阈值 2.0→2.5，更保守）。

4.3 历史事件库扩充（15 → 17）

原库偏向供应中断（正收益），缺需求侧冲击参照。新增：

事件	类型	typical_30d	补充的参照空白
美中贸易战冲击（2018-09）	macro	-12%	贸易政策驱动的需求下调
俄乌后地缘溢价消退（2022-06）	supply_policy	-22%	地缘高峰后的价格回调

并移除了一个噪声触发条件（gdelt_ci<-6.5 单独触发，验证集触发 136 天但平均目标仅 +0.9%，信噪比过低）。

4.4 改进效果

期间	改进前方向准确率	改进后
Mar - Apr 封锁高峰	~54%	71.4%
Apr - May 封锁后段	~39%	69.6%
OOS 整体（2026+）	46.7%	57.6%

第五部分 失败的尝试（同样具有参考价值）

诚实记录几条经过验证、最终放弃的改进方向，因为它们揭示了系统的本质约束。

- 1. 价格领先信号触发（price_geo_signal）。
设想：金融市场对信息的反应远快于物理数据（油轮通过量、GDELT 事件数都是滞后指标）。于是尝试用“油价 5 日涨幅>7% 或单日>4%，且 VIX<30、无 OPEC 事件”作为地缘供应冲击的领先触发。
结果：该条件确实能在 2026-02-18（单日 +4.5%）就捕捉到封锁前兆，比物理数据早。但在验证集上，同类信号 90% 后续是均值回归（短期急涨后回落，10 日收益为负），整体净效果为负。
教训：同一个“价格急涨”信号，在正常市场是均值回归前兆，在真实供应中断时才是趋势开始——模型无法区分二者，除非已知背后是否有真实的持续性事件。放弃该条件。
- 2. 情感列训练剔除实验（见 2.2）。证明 Enhanced<Baseline 与情感列无关，是高维特征集在 OOS 段的信噪比问题。已回滚。
- 3. 补抓 2 月 16 日新闻。

试图为封锁公告日补充新闻数据。结果发现 NewsAPI 免费档只能回溯 30 天；MediaCloud 专项查询 2 月份霍尔木兹相关新闻，最早一条是 2 月 18 日，且 2 月 14 - 17 日英文主流媒体完全空白。这本身是一个发现：金融市场的反应早于英文主流媒体的报道（市场通过金融情报、官方电台、阿拉伯语媒体等渠道先行定价）。

第六部分 系统的能力边界（诚实声明）

本轮审查最有价值的产出，是清晰界定了系统做不到什么，以及为什么这不是缺陷而是物理上限。

1. 滞后指标 vs 领先指标的结构性差距。

OilSense 全部数据源都是滞后指标：

数据源	滞后特性	封锁生效日 (3-02) 前的状态
PortWatch 通过量	周频 + ffill, 约 1 - 2 周	仍显示正常
GDELT 冲突事件数	周一采集量天然偏低	公告周一仅 83 条（前一日 490）
hormuz z-score	90 日均值自适应	封锁前因抢渡反而为正值 (+1.99)
RSS 新闻情感	当日批处理，需脚本按时运行	2 月整月未采集

而真实金融市场用的是领先指标（原油波动率指数 OVX、期货曲线 Backwardation、CDS 利差、做市商报价），分钟级响应。这是架构层面的差距，非参数可弥补。

2. 信息不对称的物理上限。

预封锁期（Jan - Feb 2026）方向准确率仅约 19.5%，是整个 OOS 段最差的。原因不是模型缺陷：这些日期的 10 日 target 窗口横跨了 2 月 28

日的美以空袭——一个发生在德黑兰会议室、当天无任何可观测物理信号的政治决策。模型在 t 日看到的特征完全正常（VIX≈16、油轮正常通行），却被要求预测一个尚未发生的黑天鹅。任何基于历史统计的模型（含 Bloomberg、IEA 的实时系统）在事件公告前都无法做到这一点。

3. 两次“宣布型事件”对称地暴露了同一边界。

- 2026-02-28 美以空袭（利空转利多起点）→ 3-02 市场定价，油价启动。
- 2026-04-08 临时停火（宣布即生效）→ 当日油价暴跌 -16%，而 PortWatch 物理数据仍显示封锁（油轮仍极少）。

两次系统都“反应慢半拍”，本质相同：物理数据正确反映了海峡的客观状态，但无法捕捉政治宣布对市场预期的即时冲击。

这恰恰印证了双层架构的设计初衷——第一层（统计模型）负责可观测信号的量化，第二层（情景匹配）负责极端事件锚定，而人类研判负责不可观测的政治宣布。系统知道自己的边界，比假装能预测一切更专业、更可信。

第七部分 答辩问答预案

Q：你们系统为什么没能在封锁第一天就预警？

A：事实上系统在封锁正式生效的首个交易日（2026-03-02，IRGC 官方宣布关闭日）即触发了第二层。此前一度认为存在“14 天延迟”，但事实核查后确认那是因为内部文档把起始日误标为 2 月 16 日——那天并无封锁事件。真实的不可预测窗口是 2 月 28

日空袭前的“信息盲区”，这属于所有统计模型的共同物理上限，而非本系统的特定缺陷。

Q：回测里 2 月 20 日实际涨跌幅高达 +36%，模型却预测接近 0，是不是失败了？

A：图中“实际涨跌幅”是前瞻指标——指当日起向后 10 个交易日的实际收益。2 月 20 日的 +36% 是因为该 10 日窗口恰好覆盖了 2 月 28 日空袭，而非当日市场已上涨。模型在 2 月 20 日看到的特征完全正常，给出中性预测是合理的。我们已在图例标注“实际涨跌幅（10 日后）”以消除歧义。

Q：Enhanced 模型方向准确率为什么不如 Baseline？

A：经核查，原历史情感数据因数据管道缺陷（keep_days=90 滚动裁剪）丢失，导致情感特征在训练集中长期为零。我们已重建 2022 - 2026 历史情感数据（647 天），但交易日覆盖率仍仅 33 - 37%，过于稀疏，XGBoost 难以利用。系统实际采用分工设计：Baseline 负责方向预测（57%），Enhanced 负责风险区间（覆盖率 93.6%）。真正的差异化来自 GDELT 与 PortWatch 航运数据，这两项在特征重要性中名列前茅且真实有效。

Q：第二层情景匹配可靠吗？

A：封锁期（hb=1）区间覆盖率达 96.1%，方向准确率 71%，证明在真实极端事件中有效。但它依赖人工标注的历史事件库 typical_30d，且无法预知“停火”这类宣布型反转（4-08 停火当日油价 -16% 时第二层仍看涨）。这是情景匹配的已知局限，须配合人工研判使用。

附录 A 核心指标对比

指标	提交版	改进版
区间覆盖率（验证集）	76%（整体口径）	93.6%
区间覆盖率（封锁期）	未评估	96.1%
Mar - Apr 封锁高峰方向准确率	未评估	71.4%
Apr - May 封锁后段方向准确率	未评估（约 39%）	69.6%
OOS 整体方向准确率（2026+）	46.7%	57.6%
封锁 50 天内第二层有效激活	10 天	50 天
历史情感数据覆盖	43 天	647 天
MediaCloud 历史新闻	2311 条 / 360 独立日	3708 条 / 587 独立日
历史事件库规模	15 个	17 个
全样本第二层触发率	—	14.3%（226 天）
封锁 typical_30d	0.35→0.45（错误起点）	0.59（修正起点）
回测展示范围	止于 10 日前	延伸至今日
SHAP 逐日因子归因		
双源 AIS 实时航运		（ShipFinder+VesselAPI）

附录 B 代码/数据改动文件清单

代码：app.py（门控+展示+SHAP+指标面板）、extreme_scenario.py（触发+分类器+事件库+日期）、fetch_portwatch.py（冻结基准+编码）、update_daily.py（接入 SHAP/航运）、train_model.py（编码）。

新增模块：shap_explain.py（TreeSHAP 因子归因）、shipping_sources.py（双源 AIS）。
数据：feature_matrix、daily_sentiment（647 天）、news_sentiment_detail（5325 条）、mediacloud_history_weekly（3708 条）、recent_features（展示延伸至今日）、shap_*.csv、portwatch（更新至 2026-05-24）。

附录 C 未解决问题与后续建议

问题	性质	建议
Enhanced 方向准确率 < Baseline	数据密度限制	维持现有分工；若要激活情感因子需新闻源达到每交易日稳定覆盖
预封锁期方向准确率低	物理上限（信息不对称）	非缺陷，答辩中作为“系统边界认知”正面陈述
滞后指标响应慢	架构限制	长期可引入 OVX/期货曲线等市场领先指标
情景匹配无法预知宣布型反转（如停火）	方法局限	配合人工研判；可考虑新闻关键词直触发机制

本报告基于 2026 年 5 月 30 日前的全部代码改动、数据分析与事实核查结果整理。所有指标均可通过仓库内脚本复现。